


머신러닝 강의 필기 2016104109 김성우 컴퓨터공학부

SVM → Support Vector Machine
Margin을 최대화.



$$\text{Margin } 2s = \frac{2}{\|w\|_2}$$

Minimize: $J(w) = \frac{1}{2} \|w\|_2^2$

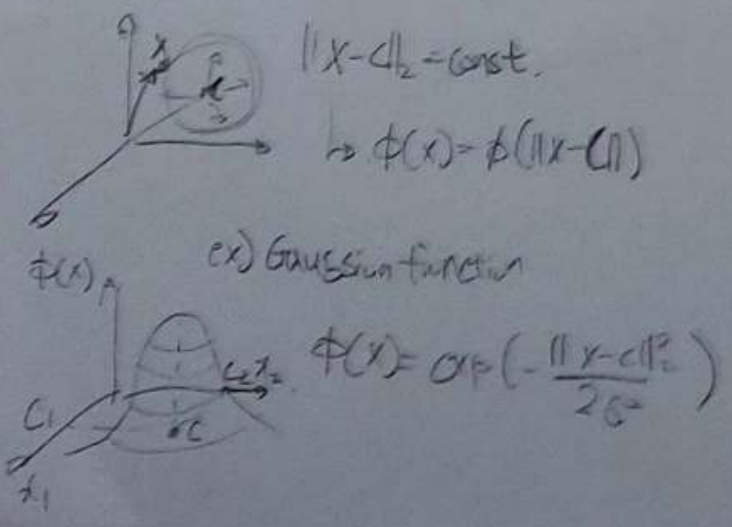
Non linear SVM, Kernel SVM

Feature Space Conversion

→ 차원도 사용된 공간의 Δ 선형 분리 가능함

- 1) Perceptron을 이용한 2차원 → 2차원 변환.
- 2) Gaussian function을 이용한 2차원 → 11.

RBF (Radial Basis Function)



3) 2차원 → 3차원 공간으로의 변환.

$$\Phi(x) = (\phi_1(x), \phi_2(x), \phi_3(x))^T$$

$$= (x^2, \sqrt{2}x, x^3)^T$$

ex) $a = (0, 0)^T \rightarrow \hat{a} = (0, 0, 0)^T$

$b = (1, 0)^T \rightarrow \hat{b} = (1, 0, 0)^T$

Kernel Trick

→ 공간 변환에 의한 계산 효율성

→ 어떤 식이 어떤 변환을 유도할 때.

1. 어떤 kernel 함수를 채택할까?

→ 모든 데이터/변에 공간 (변)을 사용

$$f(x_1^T x_2)$$

↓

$$f(k(x_1, x_2))$$

Kernel Func.

특정 공간 L에 존재하는 x, z에 대해

$k(x, z) = \phi(x) \cdot \phi(z)$ 인 변환을 통해
구현 가능한 k(x, z)를 + 변환을 도입.

Polynomial $k(x, z) = (x \cdot z + 1)^p$

Gaussian $k(x, z) = \exp(-\frac{\|x - z\|^2}{2\sigma^2})$

Hyperbolic Tangent $k(x, z) = \tanh(\gamma(x \cdot z + c))$

Mapping

$$\phi(x) \cdot \phi(z)$$

공변성

→ 선형 분리가 가능